

华北电力大学

毕业设计（论文）开题报告

学生姓名：蒋伦吉 班级：计算2202

所在院系：控计学院 所在专业：计算机科学与技术

设计（论文）题目：基于机器学习的无人机博弈对抗研究

指导教师：刘春阳

2026年 3月 7日

选题背景和意义

近年来，人工智能技术在实时对抗领域的应用日益广泛，机器博弈对抗作为智能决策的典型场景，已成为各国研究的热点方向。无人机博弈对抗要求智能体在复杂、动态、不确定的环境中，根据实时态势自主做出最优决策，这对传统基于规则的方法提出了严峻挑战。

强化学习（Reinforcement Learning, RL）作为机器学习的重要分支，为序列决策问题提供了一套系统的解决框架。Sutton 和 Barto 在其经典著作中系统阐述了强化学习的核心思想：智能体通过与环境的交互，以试错的方式学习从状态到动作的最优映射，以最大化累积奖励，实现个体的不断进化 [11]。与监督学习和无监督学习不同，强化学习不依赖标注数据，而是通过奖励信号驱动探索与利用的平衡，这一特性使其天然适用于博弈对抗场景。

多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）进一步将单智能体范式扩展到多智能体共存的环境。在无人机博弈对抗中，多个无人机之间既存在合作关系，也存在竞争关系（如与敌方无人机的对抗），同时还涉及混合动机下的协调问题。因此，研究多智能体强化学习算法在无人机博弈对抗中的应用，不仅具有重要的理论价值，也对提升集群的智能化水平具有现实意义。

本课题旨在设计并实现一套基于多智能体强化学习的无人机博弈对抗系统，利用 Godot 引擎构建二维仿真环境，开发个人创意游戏《Tiny Swords》，该游戏是一个2D俯视角混战竞技场，旨在作为多智能体强化学习的博弈环境。四名角色（Agent）在一个封闭的竞技场中进行自由对抗，通过移动与近战攻击争夺分数。游戏在核心对抗之上叠加了少量环境交互元素（野生怪物、分数球），以丰富策略空间并产生更具层次的博弈行为。

国内外研究现状

强化学习是一门关于个体进化的科学，智能体与环境不断交互并改进自身策略，逐步获取更高的奖励。强化学习由两部分组成：智能体和环境。智能体在环境中进行观测，并根据观测结果选择一个动作执行，环境接受智能体的动作并做出响应，包括环境的状态变化和给予智能体的奖励信号，智能体根据新的观测和上一步动作的奖励改进自身行为策略，以期在长期内获得最大的累积奖励[14]。图 2.1描述了强化学习的基本框架。

强化学习系统的构成要素

一个强化学习系统一般包括如下的几个要素：

（1）动作（a）与状态（s）：

智能体在环境中进行观测，得到的观测数据就是状态（state），智能体根据状




图 2.1: 强化学习基本框架

态，选择一个动作（action）并执行该动作。

（2）policy（策略）：

policy是从智能体针对环境所制定的行动方案，通常用策略函数或策略表格 $\pi(a|s)$ 表示， a 是智能体在状态 s 下的动作， s 是智能体观察到的状态。对于离散动作，策略可以是确定性的或者随机的，而对于连续动作，策略通常以概率分布表示，策略将是随机的。

（3）reward（奖励）：

reward是智能体执行动作后环境给予智能体的信号，通常用奖励函数（reward function） $r(s, a)$ 表示，即智能体在状态 s 下执行动作 a 所获得的奖励。对于智能体，其每个时刻的目标就是在状态 s 下不断执行动作，以最大化从该状态开始，在长时间内所获得的奖励 $r(s)$ 。

（4）value function（值函数）与Q-value function（Q值函数）：

值函数是给定状态 s 和策略 π 所对应的一个值，通常用 $v_\pi(s)$ 来表示， $v_\pi(s)$ 的计算公式为：

$$v_\pi(s) = \mathbb{E}[G_t | S_t = s] \quad (2.1)$$

G_t 是状态 s 开始，到时间 t 结束的累计奖励。值函数描述在当前策略下，从状态 s 开始，所获得的奖励的期望，值函数既是在描述策略的优劣也是在描述状态的优劣，在同一策略下，不同状态的值函数通常不同，智能体会倾向于前往高价值状态；不同的策略下，值函数会不同，而智能体的目标就是学得一个策略使得对于每个状态，值函数都达到其最大值。

Q值函数是给定状态 s 、动作 a 所对应的一个值，通常用 $Q(s, a)$ 来表示， $Q(s, a)$ 的

计算公式为：

$$Q(s, a) = \mathbb{E}[G_t | S_t = s, A_t = a] \quad (2.2)$$

值函数描述状态与策略的优劣，Q值函数描述状态与动作的优劣，即在当前状态下，执行每个动作的收益期望是怎样的。

(5) model of the environment (环境模型)：

环境模型是对环境动态特性的数学描述，它定义了状态转移概率和奖励函数。在强化学习中，环境模型通常表示为四元组 (S, A, P, R) ，其中 S 是状态空间， A 是动作空间， P 是状态转移概率函数， R 是奖励函数。

状态转移概率 $P(s'|s, a)$ 描述了在状态 s 下执行动作 a 后转移到状态 s' 的概率分布。状态转移受到物理规律、游戏规则和多智能体交互的影响，具有高度的非线性和不确定性。

奖励函数 $R(s, a, s')$ 定义了智能体在特定状态下采取动作并获得新状态时所获得的即时奖励。合理的奖励函数设计对于引导智能体学习到期望的行为至关重要。

环境模型可以分为两类：已知模型和未知模型。在已知模型的情况下，可以使用基于模型的强化学习方法，如动态规划；而在未知模型的情况下，则需要使用无模型强化学习方法。

强化学习的发展历程

动态规划阶段

强化学习的理论基础是贝尔曼最优方程[1]此方程将”在特定时间点的决策问题”用”选择的奖励及选择所衍生的后续状态有关的决策问题”形式化描述。

贝尔曼最优方程试图寻找最优策略，使得对于任何状态 s ，其策略 $\pi(s)$ 所对应的值函数 $v_\pi(s)$ 都是最优的：

$$V^*(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^*(s') \right] \quad (2.3)$$

其中， a 是智能体执行的动作， $R(s, a)$ 是状态 s 下执行动作 a 所获得的奖励， γ 是折扣因子， $P(s'|s, a)$ 是状态转移概率。

基于该方程，如果环境已知，即状态转移概率已知，可以使用动态规划方法来求解最优策略，这引出了基于值函数的求解方法，即在每个状态选取能够使该状态的值函数达到最大值的动作，选择该动作后到达新的状态，并重复这个过程，直到达到最优策略。主要的求解方法包括价值迭代 (Value Iteration) 和策略迭代 (Policy Iteration)。

model-free (免模型) 阶段

当环境已知时，直接求解贝尔曼最优方程即可得到最优策略，这类方法称

为model-based（基于模型）的强化学习方法。然而在大部分任务中，环境是未知的，无从得知在某个状态执行某个动作后会转移到什么状态，甚至有时连奖励函数也不知道。

为了能够解决这类问题，model-free（免模型）方法通过直接与环境交互，从而估计环境模型，进而求解最优策略。在早期，通常使用蒙特卡洛方法，即在每个状态下进行大量随机试验，通过平均试验结果来估计Q值。这种方法解决了环境未知的问题，但需要大量数据，得等每次数据收集完成后才能进行一次策略更新。

增量学习

蒙特卡洛估计能够解决环境未知的问题，但需要大量数据，且每次数据收集完成后才能进行一次策略更新，这导致策略更新的效率低下。而TD（Temporal Difference）学习[10]通过引入一个值函数或q值的近似，每次执行动作数据收集后就更新对q值的估计并立即根据q值的估计进行策略更新，从而提高了策略更新的效率。这种逐步增量更新q值的方法数学证明有效，典型的算法包括Q-learning和SARSA。

DRL：深度强化学习

此前，强化学习的过程主要是通过存储一张q表，在与环境交互中不断更新q表，这个q表就是对于q值的估计情况。然而，这种方法在面对复杂环境时，q表的维度会非常高，导致计算量非常大，无法进行有效的学习。

这时人们想到用函数近似q值，用存储函数中的参数代替存储庞大的q表，这样极大提高了算法实际应用效率。不过，对于选择什么函数来近似q值，没有通义答案，通常认为需要根据具体问题进行实验和比较。不过，[2]和[5]相继证明了多层感知器（MLP）可以近似任何连续函数，即神经网络的万能逼近定理，这意味着不管是什么任务，神经网络都能近似出满意的q值函数。[6]将神经网络用于近似q值，取得了很好的效果，[7]改进了神经网络用于强化学习的方式，引入了主网络和目标网络，提升了训练的稳定性，DQN算法开始被广泛采用。

策略梯度与 actor-critic 方法

此前的策略更新是通过近似值函数或Q值函数来实现的，而策略梯度类方法是直接优化策略函数 $\pi_{\theta}(a|s)$ ，通过梯度下降法来更新策略参数 θ ，从而实现策略的优化。最早的策略梯度算法由[13]提出，即reinforce算法，这种方法直接优化策略函数，但是对于价值的估计是依赖蒙特卡洛方法。

之后，[12]提出把时序差分估计价值函数的方法和策略梯度相结合，这种方法同时优化策略函数和估计值函数的组合。这类将同时出现策略函数和价值函数的强化学习方法称为actor-critic方法。此后，还出现了许多变种和改进，如A2C、SAC等。

TRPO与PPO

在价值函数的估计中，如果仅仅向后看一步，会导致在估计初期有较大的偏差，而如果多采样几步，又会引入过大的方差，因此引入了GAE（Generalized Advantage Estimation）方法[9]，平衡方差与偏差。使用该方法时，如果为了偏差较小需要多

步采样估计，而为了能够充分利用多步采样的数据，需要将actor-critic方法变为off-policy的，这样就能多次利用采样数据，提高数据利用率，[4]通过重要性采样技术，提出了off-policy actor-critic方法。

此后，研究者还关心学习的稳定性问题，在 Off-Policy Actor-Critic 方法中，我们使用重要性采样来修正行为策略和目标策略的分布差异，但是这种差异可能过大，导致梯度估计的方差过大，进而致使训练过程不稳定，为了控制策略更新幅度，相继出现了TRPO（Trust Region Policy Optimization）和PPO（Proximal Policy Optimization）等算法，TRPO用目标策略和行为策略之间的KL散度约束策略优化过程，将训练过程描述为一个约束优化问题，但是约束优化类问题的求解难度较大，计算成本高。PPO算法将约束条件加入目标函数作为一个惩罚项，简化了优化求解过程，并且还有实现更为简单的PPO-clip，当行为策略和目标策略的分布差异过大时，PPO-clip会截断梯度到一定范围控制策略更新幅度，保证训练过程的稳定性。

设计（论文）的主要研究内容及预期目标

[3]的成果表明，即使不使用任何联合通信，参数共享，信息共享等手段，每个智能体拥有独立的观测和策略网络，多智能体系统也可以表现出和联合学习相近甚至更好的性能。出于简单起见，本课题采用这种IPPO方法，观察智能体行为。

[8]给出了针对稀疏奖励问题的奖励塑形方法，该方法不会改变策略最优性，但可以加速策略收敛。本课题将引入奖励塑形方法，对比奖励函数，使得智能体在训练过程中能够更快地收敛到最优策略。

本课题预期设计并开发个人游戏《Tiny Swords》作为多智能体博弈环境，并在此基础上研究奖励与观测工程，通过实验对比，分析不同奖励函数和观测工程对智能体性能的影响，同时在IPPO条件下，观察分析智能体行为是否具有博弈和协作行为。

工作进度安排

序号	设计项目名称	完成时间	备注
1	查阅资料，确定毕设题目	2026.2.20–2026.2.27	1周
2	查阅资料，完成开题报告	2026.2.27–2026.3.12	2周
3	完成系统编码工作	2026.4.1–2026.4.29	4周
4	系统测试	2026.5.4–2026.5.11	1周
5	整理开发资料，完成毕业论文	2026.5.12–2026.5.27	2周
6	完善系统，准备答辩	2026.5.28–2026.6.8	2周

参考文献

[1] Richard E. Bellman. *Dynamic Programming*. Princeton University Press, Princeton, NJ, 1957.

[2] George Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989.

[3] Christian Schroeder de Witt, Tarun Gupta, Denys Makoviichuk, Viktor Makoviychuk, Philip H. S. Torr, Mingfei Sun, and Shimon Whiteson. Is independent learning all you need in the starcraft multi-agent challenge?, 2020.

[4] Thomas Degris, Martha White, and Richard S. Sutton. Off-policy actor-critic, 2013.

[5] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.

[6] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Alex Graves, Ioannis Antonoglou, Daan Wierstra, and Martin Riedmiller. Playing atari with deep reinforcement learning, 2013.

[7] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.

[8] A. Ng, Daishi Harada, and Stuart J. Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *International Conference on Machine Learning*, 1999.

- [9] John Schulman, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations (ICLR)*, 2016. arXiv:1506.02438.
- [10] Richard S. Sutton. Learning to predict by the methods of temporal differences. *Machine Learning*, 3(1):9–44, 1988.
- [11] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, 2nd edition, 2018.
- [12] Richard S. Sutton, David McAllester, Satinder Singh, and Yishay Mansour. Policy gradient methods for reinforcement learning with function approximation. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 12, pages 1057–1063. MIT Press, 1999.
- [13] Ronald J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8(3):229–256, 1992.
- [14] 王琦, 杨毅远, 江季. *EASYRL: 强化学习教程*. 人民邮电出版社, 2022.

指导教师意见

该生在前期研究中, 对《基于机器学习的无人机博弈对抗研究》课题内容及相关领域进行了较为详尽的调研, 充分分析了课题任务及目标, 完成了开题报告。该生已掌握 Godot 引擎游戏环境搭建及 Python 强化学习训练框架的相关技术, 基于 IPPO (Independent PPO) 方法初步完成了多智能体强化学习的基础研究与实验构想, 确立了《Tiny Swords》二维混战竞技场的仿真环境搭建与智能体训练方案。在此期间, 该生学习态度认真, 遵守纪律, 毕业设计任务进展符合预期计划。后续应继续开展不同奖励函数与观测空间配置下的对比实验, 进一步分析多智能体博弈与协作行为的涌现。

指导教师签名:

2026年 3月 10日